



面向复杂遮挡与同类干扰的 训练自由视频目标分割

对象中心时序账本、重锚定与保守融合

学院 请填写

专业 请填写

学号 2352190

姓名 请填写

课程 计算机视觉

日期 2026 年 6 月 21 日

摘 要

MOSEv2 将视频目标分割 (Video Object Segmentation, VOS) 的困难从“短时外观传播”推进到“复杂真实场景中的物理实例持续确认”：目标可能在首帧即被遮挡或位于边缘，随后长期消失、尺度剧变并以不同视角重现；画面中还可能同时存在多个高度相似的同类对象。本文面向 MOSEv2 作业的严格约束——仅给定首帧真值掩码、不训练或微调、不得使用后续真值——构建了一套以 SAM 2 为稳定传播基座的训练自由重锚定系统 ReAnchor-MOSE。系统不把高置信掩码等同于正确身份，而是将推理划分为稳定传播、不确定性审计、候选再获取、身份验证、延迟提交与有界回传六个阶段。其核心包括：(1) 面向消失/重现事件的对象中心时序账本；(2) 由首帧、消失前可靠帧和同类干扰物共同构成的正/负身份记忆；(3) DINO/SAM 编码特征、几何运动约束和多模态大模型 (MLLM) 事件链推理的分工式验证；(4) 经连续帧确认后才调用 `add_new_mask/box` 的伪锚点注入；(5) 只在局部窗口改写输出、并以稳定基线为回滚点的逐对象保守融合。

在 433 个验证视频的官方提交协议下，418 个已提供视频始终保持逐路径不变，仅对剩余 15 个视频推理。平台反馈表明，原始 SAM2.1-Hiera-B+ 的 $\mathcal{J}\&\mathcal{F}'$ 约为 43.24；单纯后处理、记忆门控和广泛候选融合大多只能达到 43.26–43.30。本文方法通过三个可解释的对象级修复将分数逐步提升至 43.54：低对比小目标的官方大模型区间替换使 `z6dx46qr` 提升约 24.67 个对象分；同类袋鼠重现重锚定使 `amfdu83t` 提升约 56.40；基于“向镜头运动—边缘重现—后期消失”事件链的 `q0sizv6m:obj2` 修复使该对象由 12.34 提升至 68.29。实验同时揭示，MLLM 的语义解释并不能代替像素候选生成，视觉上合理的单帧候选也可能对应错误实例；激进融合反而从 43.44 降至 43.38。本文因此主张：复杂 VOS 的关键不在于继续调整单帧阈值，而在于建立“传播之外的新证据通路”，并让新证据经过物理一致性验证后谨慎改变模型的记忆轨迹。

关键词：视频目标分割；MOSEv2；SAM2；重锚定；困难负例记忆；多模态大模型；训练自由推理

Training-Free Re-anchoring for Complex Video Object Segmentation

Abstract. MOSEv2 stresses persistent physical-instance identity under occlusion, reappearance, tiny objects, severe appearance changes, and dense same-class distractors. Under a first-frame-mask-only and no-finetuning protocol, we develop ReAnchor-MOSE, a training-free system that retains SAM 2 as the stable propagation path but augments it with an object-centric temporal ledger, distractor-aware positive/negative memory, high-recall candidate retrieval, delayed pseudo-anchor promotion, bounded re-propagation, and conservative per-object fusion. An MLLM is used only for event interpretation and candidate veto/support; it never generates masks or independently promotes anchors. On the 433-video submission protocol, while preserving all 418 provided outputs, the system improves the measured $\mathcal{J}\&\mathcal{F}'$ from approximately 43.24 to 43.54. Detailed hidden-feedback analysis attributes the gain to three physically interpretable object-level corrections rather than broad threshold tuning. The results show that reliable progress in complex VOS requires a new evidence path for re-identification and re-acquisition, not merely safer suppression of uncertain predictions.

Keywords: video object segmentation; MOSEv2; SAM 2; re-anchoring; distractor-aware memory; multimodal large language model

目录

1	引言	6
1.1	研究背景	6
1.2	问题定义	6
1.3	核心观察与贡献	7
2	相关工作	7
2.1	SAM 2 与流式视频记忆	7
2.2	干扰感知记忆与再检测	7
2.3	SAM 3、语义提示与对象检索	8
2.4	多模态大模型的角色边界	8
3	数据、约束与失败模式	8
3.1	提交协议与不可破坏不变量	8
3.2	MOSE15 的困难结构	9
3.3	为什么可靠性阈值不足	10
4	方法	10
4.1	系统总览	10
4.2	稳定传播与三态状态机	11
4.3	锚点库与干扰感知身份记忆	11
4.4	高召回候选池	12
4.5	对象中心时序账本与 MLLM split harness	12
4.6	延迟提交与伪锚点注入	13
4.7	有界重传播与保守融合	13
5	实现细节与实验设置	13
5.1	工程结构	13
5.2	实验协议	14
5.3	候选模型与计算设置	15
6	定量结果	15
6.1	总体成绩	15
6.2	对象级增益归因	16
6.3	消融与负结果	17

7 定性分析	17
7.1 成功案例一：边缘袋鼠的离场与重现	17
7.2 成功案例二：同类小动物向镜头运动	19
7.3 仍未解决的案例	21
8 讨论	22
8.1 真正起作用的改动位于哪里	22
8.2 MLLM 的价值与限制	22
8.3 为什么仍未达到 44	22
8.4 下一步研究方向	23
9 结论	23
A 复现与审计清单	24
B 代表性实现入口	24

1 引言

1.1 研究背景

半监督视频目标分割要求模型在首帧给定目标掩码后，预测该物理实例在后续所有帧中的像素区域。早期数据集中的目标通常较大、显著且遮挡有限，因此“把首帧外观沿时间传播”已能获得较高性能。MOSE 与 MOSEv2 刻意打破这些温和条件：它们包含拥挤场景、长遮挡、消失与重现、多镜头、阴影反射、极小目标和外部知识需求，迫使模型真正解决“谁还是谁”的问题 [1]。

SAM 2 将图像分割基础模型扩展为流式视频分割器：当前帧特征通过 memory attention 读取历史掩码记忆与对象指针，掩码解码器输出目标掩码，再把结果编码回记忆以服务未来帧 [2]。这一设计兼具交互性和效率，但也引入了自回归风险：一旦某帧误跟到同类干扰物，错误掩码会成为后续的“历史证据”，从而形成稳定但错误的轨迹。SAM2Long[3] 和 DAM4SAM[4] 分别从多路径记忆树与干扰感知记忆角度说明，复杂视频中的主要瓶颈确实位于记忆治理和身份恢复，而非单帧边界质量。

本作业进一步形成了一个特殊而有研究价值的约束：验证集共 433 个视频，其中 418 个结果已提供，仅需对剩余 15 个视频使用首帧掩码推理；最终提交仍必须包含全部 433 个目录。于是，任何提升都必须同时满足两点：一方面，对极少量困难视频进行高价值修复；另一方面，绝不能破坏 418 个已提供输出和原本稳定的预测。该设置把研究问题从“平均意义上训练一个更强模型”转化为“在不训练条件下，如何审计、恢复并安全提交少量高风险实例”。

1.2 问题定义

给定视频帧序列

$$\mathcal{V} = \{I_t\}_{t=0}^{T-1}, \quad I_t \in \mathbb{R}^{H \times W \times 3}, \quad (1)$$

以及首帧中 K 个实例的标签图 $Y_0 \in \{0, 1, \dots, K\}^{H \times W}$ ，目标是在不访问 $Y_{t>0}$ 的条件下预测

$$\hat{Y}_{1:T-1} = f(\mathcal{V}, Y_0; \theta), \quad (2)$$

其中参数 θ 在本作业中固定，不允许训练或微调。对任一实例 k ，预测不仅要满足区域重叠和边界精度，还要保持物理身份一致：若 o_t^k 表示时刻 t 的真实物理对象，则输出非空掩码的前提应为“当前候选确为 o_0^k 的延续”，而不是“当前画面存在同类别对象”。

官方指标 $\mathcal{J} \& \mathcal{F}'$ 综合区域相似度 $\mathcal{J}$ 与轮廓准确度 $\mathcal{F}'$ 。本文沿用平台评测器，不重新定义其数据集级聚合；对单帧区域， $\mathcal{J}$ 为交并比

$$\mathcal{J}(M, \hat{M}) = \frac{|M \cap \hat{M}|}{|M \cup \hat{M}|}, \quad (3)$$

$\mathcal{F}'$ 衡量预测与真值边界的匹配质量。由于隐藏真值不可见，本文将平台对象级明细、模型间差异和逐帧语义审计联合用作实验反馈。

1.3 核心观察与贡献

本文的核心观察是：**掩码质量、类别相似与实例身份是三个不同层次的命题**。一个面积稳定、边界清晰且与首帧同类的候选，仍可能是错误实例。由此产生三项贡献：

1. **系统性失败归因**。基于 15 个待推理视频的逐帧审查，将主要错误统一为“可见性不确定、同类身份歧义、极小目标证据不足、运动/视角变化和复合掩码污染”，并证明纯输出压制与局部阈值门控只能降低风险，不能完成身份恢复。
2. **训练自由重锚定闭环**。构建由状态审计、候选池、正负身份记忆、MLLM 事件账本、延迟提交、有界传播和保守融合组成的闭环。该闭环在结构上区分“提出假设”“验证身份”和“写入长期记忆”，避免单帧候选直接污染主轨迹。
3. **隐藏反馈驱动的可解释验证**。所有提交保持 418 个 provided outputs 不变，并用对象级得分定位真实增益来源。最终 43.54 的提升可被三个具体物理事件解释，而非来自不可审计的全局阈值扫描。

2 相关工作

2.1 SAM 2 与流式视频记忆

SAM 2 由图像编码器、memory attention、prompt encoder、mask decoder 和 memory encoder 组成 [2]。每帧图像先被编码为多尺度视觉特征；memory attention 将当前特征与过去的空间记忆和对象指针融合；解码器在提示条件下输出掩码与质量估计；memory encoder 再将预测编码回记忆库。其优势是原生支持点、框、掩码等交互提示，并能在新提示后继续传播；因此，经过验证的后续帧掩码可以作为重锚点改变整个后续推理轨迹。

然而，原生传播采用近似贪心的历史选择。SAM2Long 将每帧的不确定性用于构建多个记忆路径，并通过树搜索保留替代假设，在无需训练的情况下提升长视频稳定性 [3]。这一工作启发本文保留 provisional branch，但其多路径仍主要来自模型自身预测，未必能在所有路径均丢失正确实例后重新生成目标候选。

2.2 干扰感知记忆与再检测

DAM4SAM 把跟踪中的干扰物显式写入记忆，使模型学习区分目标与相似负例，并以 introspection 管理何时更新记忆 [4]。其思想对 MOSEv2 极为关键：同类对象不是噪声，而应作为长期困难负例。然而，直接套用外部 tracker 在本任务的 smoke 实验中仍会

产生大面积同类复合掩码，说明“有负例记忆”并不自动等于“候选分离正确”。本文因此将负例库与对象级候选枚举、延迟提交结合，而非把外部 tracker 的非空输出直接视为改进。

2.3 SAM 3、语义提示与对象检索

SAM 3 把检测、分割与跟踪统一到更强的提示接口中，增强文本/概念提示能力 [5]。但本任务输入是首帧实例掩码，而非开放词汇类别；“找到一只仓鼠”不足以区分“找到首帧指定的那一只仓鼠”。我们的 SAM3 适配实验表明，语义候选能力可用于提高召回率，却不能替代实例身份验证。

2026 PVUW MOSE 竞赛报告进一步印证了这一点。TEP 按 regular、tiny 和 semantic-dominated 目标分路由，并以外部跟踪/MLLM 提示补充基础模型 [6]；Re-Prompting SAM 3 则在后续帧用检测器生成同类候选，通过 DINOv3 对象级检索与变换感知特征池选择新锚点，再注入视频跟踪器 [7]。本文吸收其“later-frame object retrieval”范式，但为作业约束增加三项安全机制：困难负例 margin、连续帧确认与局部窗口回滚。

2.4 多模态大模型的角色边界

MLLM 能描述“拿起—遮挡—移动—放下”或“向镜头靠近—从下边缘重现”等事件链，但直接输入大尺寸多帧 panel 容易超时，且模型输出的坐标与掩码精度不稳定。本文采用 split harness：先对少量关键帧做短视觉 caption，再由深度思考模型在纯文本层聚合事件链。MLLM 仅负责目标画像、候选支持/否决和状态路由，不能直接输出最终掩码，也不能单独提升锚点。这一边界避免将语言合理性误当作像素正确性。

3 数据、约束与失败模式

3.1 提交协议与不可破坏不变量

实验遵守以下硬约束：

- 不训练、不微调、不使用后续真值；公开预训练权重仅作为推理候选源，并在报告中标记其提交资格；
- 418 个 provided outputs 必须路径一致且内容不变；
- 15 个待推理视频的第 0 帧必须逐像素保留给定标签；
- 最终压缩包包含 433 个视频目录与 66,526 张 PNG，标签值、帧数和命名均由验证器检查；
- 新方法写入独立预测根目录，任何失败均可回滚到 SAM2/M11 稳定基线。

3.2 MOSE15 的困难结构

图 1 展示四类典型困难。与常规 VOS 相比，它们不是简单的低置信帧，而是观测条件和物理身份同时改变。



图 1: MOSE15 典型困难。绿色为首帧指定实例；右列为后续原帧。依次包含遮挡后同类切片重现、边缘目标离场/重现、手部操作导致的身份转移，以及极小旋转语义物体。

表 1: 主要失败模式及其对算法的要求。

失败模式	现象与根因	必需能力
长遮挡/重现	连续若干帧无可见像素；重现时尺度、视角和位置均改变	显式 absent 状态、消失前锚点库、后续全局再获取
同类干扰	错误对象与目标类别和局部纹理高度相似，错误掩码也可很稳定	每个同类对象独立建模、困难负例库、正负 margin
首帧残缺/边缘	初始化只包含头部、边缘或被遮挡局部，完整重现反而与首帧不像	多锚点正例池、上下文/运动证据、对残缺外观降权
极小目标	面积通常不超过图像的 1%，特征网格内不足数个 token	高分辨率 crop、检测候选、找到身份后再做局部细化
快速运动/形变	模糊、转体、尺度变化使相邻帧外观匹配失效	长程事件链、运动可达性、多帧延迟确认
复合掩码	自动 mask 或外部 tracker 把目标、人手、背景和同类对象合并	实例分离、复合区域否决、局部重传播与回滚

3.3 为什么可靠性阈值不足

早期 M2 采用面积、中心位移、阈值扰动稳定性和内部 IoU/objectness 作为 memory gate。这类特征能发现“明显坏掩码”，却无法发现“稳定地跟错了另一只同类动物”。令 q_t 表示掩码质量， i_t 表示身份正确性，则实践中存在

$$q_t \approx 1 \quad \text{但} \quad i_t = 0. \quad (4)$$

如果仍用 q_t 更新 previous state，错误候选会迅速成为新的几何参考；后续所有运动检查都围绕错误轨迹展开。M11 的输出级 cycle gate 更安全，但只能把可疑片段清空，不能生成正确目标。由此可见，系统必须提供传播之外的独立候选源和身份证据。

4 方法

4.1 系统总览

ReAnchor-MOSE 的设计原则是：**稳定区间尽量不改，恢复区间同时保留多个假设；只有经身份与时序共同确认的新证据才能改变主记忆。**图 2 给出总体结构。




图 2: ReAnchor-MOSE 总体架构。蓝色为基础分割/传播，黄色为不确定性与候选生成，绿色为身份恢复，红色为提交安全层。

4.2 稳定传播与三态状态机

对每个视频对象独立维护状态 $s_t \in \{\text{stable}, \text{ambiguous}, \text{recovery}\}$ 。状态输入不是单一置信度，而是一个结构化 FrameAudit：

$$a_t = (e_t, o_t, p_t, \Delta A_t, \Delta x_t, u_t, d_t), \quad (5)$$

其中 e_t 为连续空帧数， o_t/p_t 为 objectness 与预测 IoU， ΔA_t 为面积变化， Δx_t 为中心运动残差， u_t 为候选分歧， d_t 为身份 margin。稳定状态下完全沿用原始 SAM2，避免高风险控制器破坏本来正确的视频；出现空帧、置信下降、来源分歧或运动不可达时进入 ambiguous；确认目标消失或主路径失效后进入 recovery。

与二值 accept/reject 不同，ambiguous 状态允许候选继续输出到 provisional branch，但禁止写入长期身份记忆；recovery 才触发全局/局部候选再获取。只有重新确认后才回到 stable。

4.3 锚点库与干扰感知身份记忆

每个对象维护

$$\mathcal{B}_k = \{A_k^0, \mathcal{P}_k, \mathcal{R}_k, \mathcal{N}_k\}, \quad (6)$$

分别表示首帧锚点、消失前高质量正例 reservoir、已验证重现锚点和困难负例库。正例不是“最近帧”，而是身份仍清晰、形态具有代表性的帧；负例来自同帧其他对象、M11 cycle 拒绝片段、非选中自动掩码、附近同类候选、context ring 以及已知错误来源。

候选 c 的基础身份分数不是只计算与正例的相似度，而是正负差值

$$m(c) = \max_{p \in \mathcal{P}_k \cup \mathcal{R}_k} \cos(f_c, f_p) - \max_{n \in \mathcal{N}_k} \cos(f_c, f_n). \quad (7)$$

描述器 f 可由 DINOv2/DINOv3 patch token[8]、SAM2 Hiera 图像特征与颜色/形状统计融合。对普通目标，使用掩码内 token 均值与上下文环差分；对极小目标，若掩码覆盖 token 少于 3 个，则改用扩大局部框的 crop descriptor，避免全图平均淹没目标。

4.4 高召回候选池

恢复首先追求“正确目标出现在候选池中”，而非立即保证所有候选可靠。候选源包括：

1. SAM2 当前主路径和 M11 保留/拒绝 tracklet；
2. SAM2Long、官方 large/long、DAM4SAM/d4sm、SAM3/SAAS 等独立 tracker 输出；
3. SAM2 automatic mask、point-grid proposal 与高分辨率 tiny crop；
4. 后续高置信帧的反向传播候选；
5. 光流或全局相机运动引导的搜索区域；
6. MLLM 事件账本提出的空间约束（例如“下边缘重现”），但不直接采用其坐标为掩码。

这种设计把 proposal recall 与 identity precision 解耦。外部模型可以提出候选，但不会直接进入最终提交；即使多个来源一致，也需判断它们是否共享同一错误，例如都跟到更显眼的同类对象。

4.5 对象中心时序账本与 MLLM split harness

仅比较首帧与当前帧 crop，无法处理物体转体、遮挡或被拿取。本文为每个对象建立事件账本

$$\mathcal{L}_k = \{(t, v_t, r_t, \pi_t, \mathcal{D}_t)\}, \quad (8)$$

其中 v_t 为可见状态（visible/partial/absent）， r_t 为相机与目标相对运动， π_t 为可达位置/尺度， $\mathcal{D}_t$ 为同类干扰物状态。账本回答的不只是“当前像不像”，还包括“若这是同一物体，它从上一状态如何物理地到达这里”。

受 Qwen-VL 系列视觉理解接口 [9] 启发，为避免 qwen3.6-plus 直接处理大尺寸多帧 panel 的超时和注意力稀释，我们将推理拆成两级：

1. **帧级视觉描述**：每次只输入一个小型 crop/context panel，短输出目标可见性、相对位置、动作和候选编号；超时后自动缩小为 crop-only 重试。
2. **文本级事件聚合**：将多个帧 caption 与候选表交给深度思考模型，推断“离场重现”“拿起移动放下”“向前景运动”等事件链，并输出支持、否决或不确定判断。

模型不接触后续 GT。若 MLLM 不确定，same-class dense 对象默认拒绝锚点，tiny 对象保持基线，稳定对象不启用恢复。此策略把语言模型定位为“物理故事审计器”，而非分割器。

4.6 延迟提交与伪锚点注入

单帧候选首先进入 provisional 状态。候选只有满足下列条件才可晋升：

$$\text{promote}(c_t) = \mathbf{1}[m(c_t) > \tau_m] \wedge \text{TemporalConfirm}(c_{t:t+2}) \wedge \neg \text{Veto}_{\text{MLLM}} \wedge \text{Reachable}_{\mathcal{L}}. \quad (9)$$

TemporalConfirm 默认要求连续两帧或未来三帧中的两帧具有相同来源/重叠和正 margin；若视频已接近末尾，则需要更强的 identity margin 或反向 cycle。对同类密集目标，MLLM 的高置信支持最多是附加证据，不能单独满足 promote。

验证通过后，通过 SAM2 原生接口

$$\text{add_new_mask}(t, k, M_t^*) \quad \text{或} \quad \text{add_new_box}(t, k, B_t^*) \quad (10)$$

重新驱动跟踪器，而不只是把候选 PNG 粘到输出。这样新锚点会改变 memory attention 所读到的 conditioned memory，并在前后局部窗口重新传播。

4.7 有界重传播与保守融合

重传播仅作用于锚点附近的时间窗口 $[t - r_b, t + r_f]$ ，窗口外保持稳定基线。若新轨迹与 SAM2/M11 的差异超过阈值，且身份置信不足，则整段回滚。最终融合粒度为 video/object/segment，而非像素投票：

$$\hat{M}_t^k = \begin{cases} M_{t,\text{reanchor}}^k, & t \in \Omega_k \text{ 且通过审计,} \\ M_{t,\text{M11}}^k, & \text{风险场景,} \\ M_{t,\text{SAM2}}^k, & \text{稳定场景.} \end{cases} \quad (11)$$

这使“外部候选失败”不会扩散成全视频回归，也使 418 个 provided outputs 天然保持不变。

5 实现细节与实验设置

5.1 工程结构

系统围绕统一预测根目录与审计 JSON 组织。主要模块包括：SAM2 基线推理器、重锚定入口、DINO 描述器、Qwen-VL 客户端与 panel 渲染、candidate/tracklet judge、

bounded teach-box/mask 推理器、逐对象融合器、根目录比较器与提交验证器。每次实验均记录命令、checkpoint、预测根、视觉 sheet、对象级差异和是否推荐提交。

表 2: 系统由内到外的模块与实验结论。

层级	代表方法/实现	作用与结论	判定
基础传播	SAM2.1	大部分稳定区间质量最高; large/long 可提	有效
	B+/large/long	供独立候选, 但全局替换增益很小	
输出安全阀	M11 cycle gate	清除明显错误短轨迹, 安全但不恢复目标	有效
记忆写入门控	M2 reliability gate	能抑制明显坏记忆; “稳定错误” 仍会通过	中性
状态/候选审计	RAR/M3/M5R-C	建立候选表、hard negative 和重传播框架; 初始描述器与候选召回不足	中性
外部 tracker	DAM 系列、SAM2Long、SAAS	提供不同假设; 同类复合掩码和候选相关错误限制直接使用	中性
对象描述器	DINO/SAM2 feature	比 RGB/几何更适合身份比较, 但极小/残缺对象仍困难	有效
MLLM harness	Qwen-VL/Qwen3.6 split	事件链、路由与 veto 有意义; 不能独立给出可靠像素锚点	有效
伪锚点注入	原生掩码/框提示	真正改变 SAM2 后续轨迹, 是显著增益的必要环节	有效
保守融合	per-object bounded fusion	防止风险改动扩散; aggressive 结果证明其必要性	有效
SAM3 迁移	strict SAM3 adapter	候选语义更强, 但未证明优于最终 SAM2 路径	中性

5.2 实验协议

所有候选首先在关键视频 smoke test, 只有至少两个对象出现明确改善且稳定 guard 视频无严重回归时才扩展到 15 个视频。视觉比较统一包含 RGB、SAM2、M11、候选输出、差异图和局部放大。隐藏评测反馈到达后, 使用对象级行分析增益归因, 而不把总分四舍五入后的相同值误判为等价方法。

最终提交由验证器检查: 视频目录数、PNG 总数、逐视频帧数、标签合法性、首帧保留、418 个 provided outputs 哈希/路径不变。由于后续真值隐藏, 本文把“平台对象行提升 + 多帧物理一致性 + 无 stable regression”作为接纳新策略的联合标准。

5.3 候选模型与计算设置

基础模型为 SAM2.1 Hiera-B+；官方 large/long、SAM2Long、DAM4SAM/d4sm、SAAS、SAM3 仅作为候选或上界诊断。DINOv2 ViT-B/L 用于对象级 embedding。MLLM 调用通过阿里云百炼 OpenAI-compatible 接口，视觉请求采用短超时与 mini retry，文本聚合使用 qwen3.6-plus 深度思考；所有请求按模型、prompt 和图像哈希缓存，防止重复成本和不可复现变化。

6 定量结果

6.1 总体成绩

表 3 和图 3 汇总经平台验证的代表性提交。M11 只带来约 0.02 的安全增益；M6/M7 的复杂候选与 MLLM verifier 在总分上大多停留于 43.30，说明框架存在但没有真正改变正确像素。M13、M15 与 M17 的提升则分别对应一个可定位的对象级修复。

表 3: 代表性提交的隐藏评测 $\mathcal{J}\&\mathcal{F}'$ 。分数为用户提供的平台结果；“主要来源”表示能解释净增益的对象。

提交族	$\mathcal{J}\&\mathcal{F}'$	主要变化/解释
SAM2.1-Hiera-B+	约 43.24	基础稳定传播
M11 cycle gate	43.26	输出级拒错，小幅安全增益
M6/M7 verifier/fusion	43.30	多数结构改动未产生足够有效像素替换
M13 zofficial-balanced	43.34	z6dx46qr 使用官方 large 区间输出
M15 layered-safe	43.44	amfdu83t:obj1 重现后重锚定
M17 q0 early-box	43.47	修复 q0sizv6m:obj2 早期重现缺口
M17 q0 full-box	43.54	完整前景运动路径的有界传播




图 3: 代表性提交的 $J\&F'$ 进展。曲线不是单纯模型规模增长, 而是逐对象重锚定证据通过隐藏评测后的累积。

6.2 对象级增益归因

由于共有 575 个对象行, 一个对象提升 Δs 对总体均值的贡献约为 $\Delta s/575$ 。表 4 显示, 43.54 不是由大量微小阈值变化累积, 而是由三个高价值对象推动。

表 4: 被隐藏评测验证的主要对象级修复。

对象	方法来源	修复前	修复后	总分贡献	机制解释
z6dx46qr:1	official-large 区间	40.47	65.14	$\approx +0.043$	大模型对低对比小目标保持更长有效轨迹
amfdu83t:1	M14/M15 重锚定	约 28.44	84.84	$\approx +0.098$	识别离场后的同一袋鼠并向后传播
q0sizv6m:2	M17 full-box	12.34	68.29	$\approx +0.097$	依据向镜头运动和下边缘重现修正同类错跟

M15 safe 与 balanced 同为 43.44, 说明额外的麻将候选没有贡献; aggressive 仅 43.38, 表明 1qlssuz2/4vznweiu 等未经充分验证的窗口整体有害。该结果直接支持本文的“延迟提交 + 保守融合”设计: 候选数量增加并不保证分数增加, 真正重要的是候选是否为同一物理实例。

6.3 消融与负结果

表 5: 关键消融的机制结论。

消融	结果	结论
只做输出阈值/cycle	小幅提升	能拒绝灾难性漂移，不能恢复遮挡后身份
只做 memory reliability gate	基本不升	mask quality 与 identity correctness 不等价
只扩大自动 mask 候选	局部更非空但风险上升	recall 提高，同时产生人/动物 composite
只接外部 tracker	smoke 多数不通过	独立模型仍可能共享同类错误，不能直接替换
MLLM 单帧候选支持	多数 43.25-43.30	能解释但缺少可靠坐标/像素，实际改动帧太少或错误
MLLM split event + verified box	对 q0 有显著增益	长程事件链必须落实为可验证候选，并重新驱动 SAM2
激进多视频融合	43.38 < 43.44	未经身份确认的“看起来更完整”候选会降低真实指标
SAM3 直接替换/严格适配	未优于 M17	语义提示能力不自动解决 first-mask instance re-ID

7 定性分析

7.1 成功案例一：边缘袋鼠的离场与重现

amfdu83t:obj1 在首帧仅露出画面最左边缘的头颈与前足，面积约为全图的 0.052%。镜头移动后目标完全出画，而画面左侧长期存在另一只更完整、更显眼的袋鼠。原始 SAM2/SAM3 路径几乎全空或受干扰物影响。对象级审查表明，真正目标应在第 8 帧附近从左下方靠近镜头重现，并以较快速度超过干扰袋鼠。经重现锚点注入后，SAM2 能沿新锚点恢复连续轨迹（图 4），对象分由约 28.44 提升至 84.84。



图 4: amfdu83t:obj1。中列红色为 SAM2 基线，右列绿色为最终重锚定融合。修复的关键不是增强首帧相似度，而是把“离场—左下重现—向前运动”作为身份连续性证据。

7.2 成功案例二：同类小动物向镜头运动

q0sizv6m 含多只高度相似的小动物。obj2 在首帧位于左/下边缘，随后朝镜头靠近并短暂消失；第 6 帧可见鼻部，第 7 帧出现小头，第 8 帧上半身进入画面。基线在第 13 帧后重新锁定旧位置附近的另一只同类对象，类别正确但物理身份错误。

M17 将事件账本具体化为一个前景/下边缘空间约束，并以 box prompt 生成候选，再由 SAM2 有界传播。平台明细显示该对象从 12.34 提升至 68.29。图 5 也显示，系统由“旧位置同类匹配”转向“沿向镜头运动链重现”。不过第 31 帧附近仅剩臀部边缘、第 34 帧后应消失，最终输出仍有晚期误检，因此该案例同时说明事件账本还需要显式 visible/partial/absent 调度。




图 5: q0sizv6m:obj2 的关键帧。最终方案显著纠正了同类错跟, 但晚期可见状态仍非完全准确。

7.3 仍未解决的案例

图 6 展示三类主要残余错误。




图 6: 残余困难案例。视觉上“非空且合理”的输出仍可能标错物理实例，因此不得仅凭单帧完整性判断改进。

麻将身份转移 (8jsm23a7)。 首帧目标麻将背面朝上，与待摸牌高度相似；第 1 帧被手遮挡，第 3–5 帧在运动模糊中可见七条特征，第 6–7 帧被放到面前牌列最左侧。早期 MLLM prompt 将“左侧牌”过度语言化，候选实际落在远处/上方牌列的二条，平台对象分仍约 2.13。该失败说明事件描述必须绑定可视证据和候选 ID，不能把用户叙述直接变成指向性坐标提示。

草莓切片 (r13u5z4y)。 首帧目标只露出被遮挡的一小段边缘，之后被手完全挡住并与另一切片同时移动。第 20 帧后目标重现于多个近似切片旁。M11 的空输出虽保守，却比错选原位置草莓更安全。当前候选源无法稳定枚举并分离每个切片，因而身份验证无从发挥。

旋转字母骰子 (4vznweiu)。 目标极小且自身旋转，表面字母随视角改变，邻近还有多枚相似骰子。高分辨率 crop 能改善可见性，却不能决定实例身份；先前 aggressive 窗口

发生向相邻字母骰子的切换。正确方向是“同类对象全部编号 + 相对运动轨迹 + 多面外观记忆”，而不是继续扩大 crop。

8 讨论

8.1 真正起作用的改动位于哪里

从整条链路看，基础模型并非主要短板：SAM2 在目标连续可见时通常表现良好。有效改动集中在两个接口：

1. **恢复证据接口**：在主路径丢失后，生成一个物理上可解释、实例上可区分的后续锚点；
2. **轨迹改写接口**：把锚点通过 SAM2 原生提示重新注入，使 memory attention 读到新的 conditioned memory，并只在受控窗口提交。

M11/M2/M3 等工作有意义，因为它们建立了安全阀、审计和候选表，但在没有高质量 later-frame anchor 时只能“少犯错”。M15/M17 首次显著提升，是因为它们完成了从事件理解到候选坐标、再到 SAM2 传播和提交融合的闭环。

8.2 MLLM 的价值与限制

MLLM 对本任务最有价值的能力不是类别识别，而是把离散帧组织为物理事件：目标是否被拿起、是否向镜头移动、是否真正离场、哪一个同类对象的运动与历史兼容。split harness 提高了调用稳定性，也减少大 panel 中的视觉遗漏。然而，语言模型仍存在三类限制：

- 空间精度不足：正确故事不保证正确 bbox，更不保证像素边界；
- 提示偏置：具体视频叙述可能诱导模型寻找“被提示的对象”，形成高置信错选；
- 同类不可辨识：若帧中没有可观察的实例差异，任何语义模型都无法从单帧恢复身份，只能依赖运动和完整事件链。

因此，MLLM 应输出“候选之间的关系与风险”，并由传统视觉候选/描述器落实到像素。未来可让其维护结构化 scene graph，但仍需通过独立视觉 evidence gate。

8.3 为什么仍未达到 44

从 43.54 到 44 仍需约 0.46 个全局分，相当于 575 个对象行总计约 265 分。已修复的三个对象各贡献约 0.04–0.10，说明需要再完成数个类似量级的真实身份恢复。8jsm23a7

理论潜力最大，但候选身份仍错；r13u5z4y、4vznweiu、1qlssuz2 的可见像素少且同类密集。瓶颈不再是 pipeline 缺失，而是：

$$\text{正确实例是否进入候选池} \quad \text{以及} \quad \text{能否在无 GT 下被可靠区分}. \quad (12)$$

这要求更强的全视频对象提议与多对象轨迹维护，而不是继续扫描阈值。

8.4 下一步研究方向

1. **多对象 candidate graph**。对每个关键帧的全部同类候选建立节点，以光流、可达速度、遮挡关系和外观 margin 建边；目标恢复转化为带 absent state 的全局路径搜索。
2. **DAM 与延迟 DRM promotion 深度融合**。不只保存目标正例，还为每个同类干扰物维护独立记忆与运动状态；只有分支在未来帧持续与正例接近且远离负例，才晋升到主记忆。
3. **SAM3 作为 proposal teacher**。利用语义/概念 prompt 枚举同类候选，但继续由对象级 retrieval 和时序账本做实例选择；SAM2 仍可作为最终稳定传播器。
4. **双向与多锚点一致性**。从多个后续锚点前后传播，选择能同时解释首帧、消失前和重现后观测的路径，避免单锚点偶然匹配。
5. **不确定性校准**。用候选间相对 margin 和来源相关性替代绝对置信度；“多个模型一致”只有在其错误机制独立时才构成强证据。

9 结论

本文针对 MOSEv2 中遮挡、重现、同类干扰和极小目标造成的实例身份丢失，构建了一套训练自由的对象中心重锚定系统。大量负结果表明，输出阈值、记忆写入门控、局部 crop 或单一外部 tracker 都不能单独解决身份恢复；它们最多降低错误传播。真正有效的路径是：在基础传播之外生成后续对象候选，以正负身份记忆和物理事件链验证，再通过原生 prompt 接口重写 SAM2 的局部记忆轨迹，最后以逐对象保守策略融合。

在保持 418 个 provided outputs 不变的前提下，系统将隐藏 $\mathcal{J}\&\mathcal{F}'$ 从约 43.24 提升至 43.54。更重要的是，提升来源可以被明确归因到低对比小目标、同类袋鼠重现和前景小动物运动三个实例，而激进候选的回归也被隐藏评测证实。本文的主要结论不是“某个阈值最优”，而是：复杂视频分割需要从单路径自回归升级为“传播、审计、再获取、验证、延迟提交、回滚”的闭环；语义模型只有在与对象级候选和时序几何对齐后，才会转化为真实像素收益。

A 复现与审计清单

1. 运行预测时为每个方法使用独立 `pred_root`、`audit_json` 和日志目录；
2. 用 `tools/compare_candidate_roots.py` 检查逐视频变化、空帧数、来源 IoU 和首帧保持；
3. 用统一 compare sheet 人工核对原帧语义、目标 ID、候选来源和局部放大；
4. 仅将视觉与时序均通过的对象区间写入 fusion policy；
5. 用 `tools/validate_mose_submission.py` 检查 433 个目录、66,526 张 PNG、标签合法性和 418 个 provided outputs 不变；
6. 保存 zip 的 SHA256、平台总分及对象级明细，避免只依据两位小数总分作归因。

B 代表性实现入口

路径	功能
<code>tools/infer_mosev2_sam2.py</code>	SAM2 首帧掩码基线
<code>tools/infer_mosev2_sam2_reanchor.py</code>	候选验证、延迟提交与伪锚点重传播
<code>src/cvmose/dino_descriptor_s.py</code>	DINO 对象级正/负描述器
<code>src/cvmose/qwen_vl_client.py</code>	可缓存、可降级的百炼 Qwen-VL 客户端
<code>tools/mlm_event_story_split.py</code>	帧级视觉描述与文本事件聚合 split harness
<code>tools/infer_mosev2_sam2_teach_boxes.py</code>	经验证 box 的 SAM2 注入与有界传播
<code>tools/apply_m17_q0_story_fusion.py</code>	q0 可见状态与逐对象区间融合
<code>tools/validate_mose_submission.py</code>	提交结构与 provided-output 不变量验证

参考文献

- [1] Henghui Ding, Kaining Ying, Chang Liu, Shuting He, Xudong Jiang, Yu-Gang Jiang, Philip H. S. Torr, and Song Bai. Mosev2: A more challenging dataset for video object segmentation in complex scenes. *arXiv preprint arXiv:2508.05630*, 2025.
- [2] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman R”adle, Chloe Rolland, Laura Gustafson, et al. Sam 2: Segment anything in images and videos. *arXiv preprint arXiv:2408.00714*, 2024.
- [3] Shuangrui Ding, Rui Qian, Xiaoyi Dong, Pan Zhang, Yuhang Zang, Yuhang Cao, Yuwei Guo, Dahua Lin, and Jiaqi Wang. Sam2long: Enhancing sam 2 for long video segmentation with a training-free memory tree. *arXiv preprint arXiv:2410.16268*, 2024.
- [4] Jovana Videnovic, Alan Lukezic, and Matej Kristan. A distractor-aware memory for visual object tracking with sam2. *arXiv preprint arXiv:2411.17576*, 2024.
- [5] Nicolas Carion, Laura Gustafson, Yuan-Ting Hu, Shoubhik Debnath, Ronghang Hu, Didac Suris, Chaitanya Ryali, Kalyan Vasudev Alwala, Haitham Khedr, Andrew Huang, et al. Sam 3: Segment anything with concepts. *arXiv preprint arXiv:2511.16719*, 2025.
- [6] Jinrong Zhang, Canyang Wu, Xusheng He, Weili Guan, Jianlong Wu, and Liqiang Nie. Advancing complex video object segmentation via tracking-enhanced prompt: The 1st winner for 5th pvuw mose challenge. *arXiv preprint arXiv:2604.00395*, 2026.
- [7] Mingqi Gao, Sijie Li, and Jungong Han. Re-prompting sam 3 via object retrieval: 3rd of the 5th pvuw mose track. *arXiv preprint arXiv:2603.23788*, 2026.
- [8] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaa El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024.
- [9] Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibao Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, et al. Qwen2.5-vl technical report. *arXiv preprint arXiv:2502.13923*, 2025.